


Control Automático


Introducción al filtro de Kalman

Contenido




- Principio de funcionamiento
- Ecuaciones de predicción y actualización
- Proceso
- Ejemplo

Principio de Funcionamiento




- Es un método recursivo para estimar el estado de un sistema **lineal** minimizando la media del error cuadrático
- Mediante el conocimiento del comportamiento actual, el filtro de Kalman estima el estado futuro del sistema aplicando un término de **corrección** proporcional al factor de predicción.

Clases de filtros de Kalman




- El filtro de Kalman continuo
 - Aplicable a sistemas continuos **lineales**
- El filtro de Kalman discreto ✨
 - Aplicable a sistemas discretos **lineales**
- El filtro extendido de Kalman
 - Aplicable a sistemas discretos **no lineales**

Ecuaciones de predicción




- Son responsables de la proyección del estado al momento “k” tomando como referencia el estado en el momento “k-1” y la actualización intermedia de la matriz de covarianza del estado.

Ecuaciones de actualización



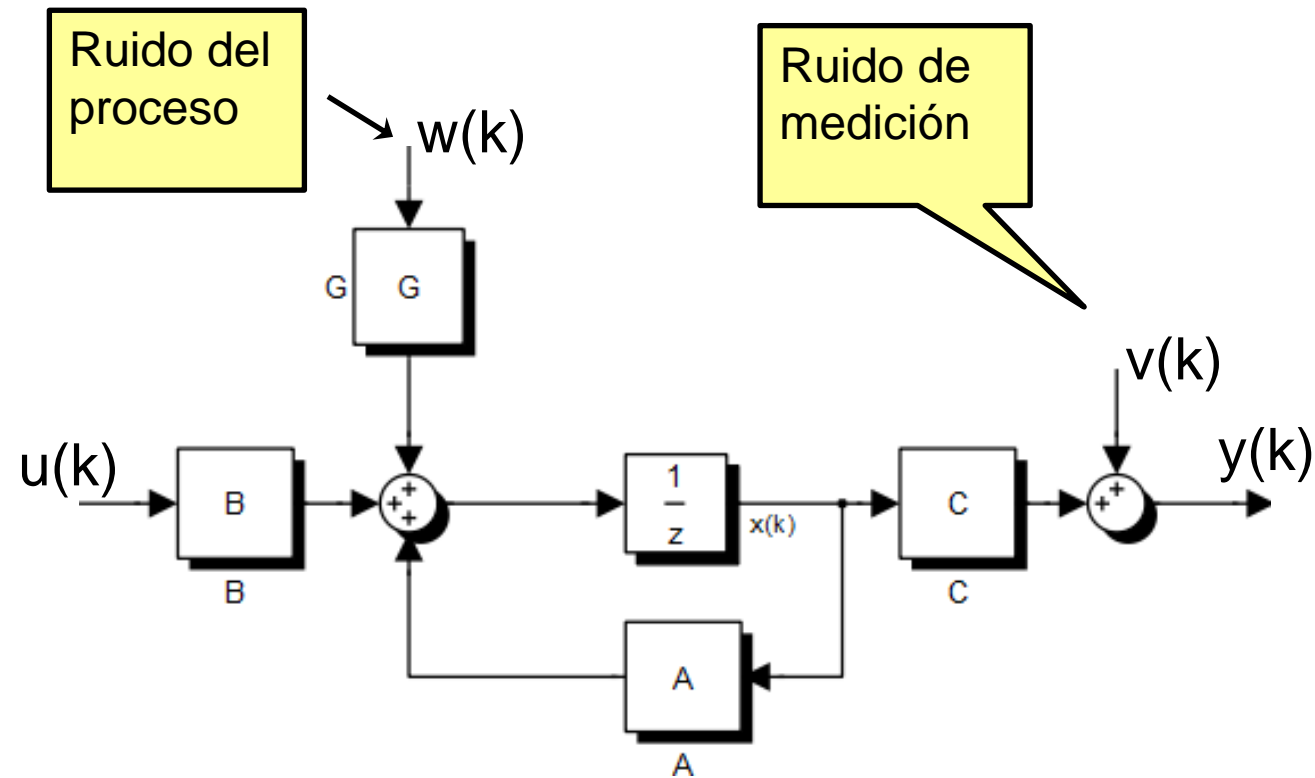

- Son responsables de la retroalimentación, es decir, incorporan nueva información dentro de la estimación anterior con lo cual se llega a una estimación mejorada del estado.

Aplicaciones




- Estimación de parámetros que cambian en el tiempo.
- Estimación del estado de un sistema en el pasado, presente y futuro, aún cuando la naturaleza precisa del sistema modelado es desconocida.
- Estimación en presencia de ruido

Planta en tiempo discreto como un proceso estocástico




- Vamos a suponer **A**, **B** y **C** constantes y $G = 1$

Condiciones de operación




- Los ruidos de proceso y de medición deben ser independientes entre sí, ruidos blancos (no correlacionados consigo mismo) y de distribución normal de probabilidad.
- Las matrices de covarianza de ruido de proceso, Q , y de covarianza de ruido de medición, R , se suponen constantes; aunque pueden variar ligeramente entre cada paso de medición
- También se supone que A y C son constantes; pero podrían cambiar en el tiempo

Ecuaciones del proceso



- $\mathbf{x}(k) = \mathbf{A}\mathbf{x}(k-1) + \mathbf{B}u(k-1) + \mathbf{w}(k-1)$
- $y(k) = \mathbf{C}\mathbf{x}(k) + v(k)$
- Usaremos, para facilitar la escritura, la notación sin paréntesis para el ordinal k , ej.: $\mathbf{x}(k)$ será entonces escrita \mathbf{x}_k

Valores que se deben conocer



- Se debe conocer el ruido del proceso $w(k)$ y el ruido de medición $v(k)$ que son secuencias aleatorias de media cero, esto es:


$$E\{w(k)\} = E\{v(k)\} = 0$$

- Y las covarianzas de ruido de proceso y de medición:

$$E\{w(k)w^T(k)\} = \mathbf{Q}(k)$$

$$E\{v(k)v^T(k)\} = \mathbf{R}(k)$$

Los errores



- Si $\hat{\mathbf{x}}_k^-$ es el estimado a *priori* del estado en el tiempo k , conocidos el proceso antes del tiempo k y $\hat{\mathbf{x}}_k$ es el estimado a *posteriori* del estado en el tiempo k , dada la medición y_k .


- El error a priori

$$\mathbf{e}_k^- = \mathbf{x}_k - \hat{\mathbf{x}}_k^-$$

- El error a posteriori

$$\mathbf{e}_k = \mathbf{x}_k - \hat{\mathbf{x}}_k$$

La covarianza




- La covarianza del estimado a *priori* del error

$$\mathbf{P}_k^- = E[\mathbf{e}_k^- \cdot \mathbf{e}_k^{-T}]$$

- La covarianza del estimado a *posteriori* del error

$$\mathbf{P}_k = E[\mathbf{e}_k \cdot \mathbf{e}_k^T]$$

El estado estimado *a posteriori*




- Se calcula como una combinación lineal del estado estimado *a priori* y una porción ponderada de la diferencia entre la medición y el valor estimado de la medición.

$$\hat{\mathbf{x}}_k = \hat{\mathbf{x}}_k^- + \mathbf{K}_k (y_k - \mathbf{C}\hat{\mathbf{x}}_k^-)$$

- La diferencia entre la medición y su estimado se llama ***innovación*** de la medición o residuo.
- La matriz \mathbf{K} se escoge para minimizar la covarianza del error *a posteriori*

$$\mathbf{K}_k = \mathbf{P}_k^- \mathbf{C}^T (\mathbf{C} \mathbf{P}_k^- \mathbf{C}^T + \mathbf{R})^{-1} \quad \begin{cases} \lim_{\mathbf{R}_k \rightarrow 0} \mathbf{K}_k = \mathbf{C}^{-1} \\ \lim_{\mathbf{P}_k^- \rightarrow 0} \mathbf{K}_k = \mathbf{0} \end{cases}$$

El proceso del filtro



a posteriori

$$\mathbf{K}_k = \mathbf{P}_k^- \mathbf{C}^T (\mathbf{C} \mathbf{P}_k^- \mathbf{C}^T + \mathbf{R})^{-1}$$

$$\hat{\mathbf{x}}_k = \hat{\mathbf{x}}_k^- + \mathbf{K}_k (y_k - \mathbf{C} \hat{\mathbf{x}}_k^-)$$

$$\mathbf{P}_k = (\mathbf{I} - \mathbf{K}_k \mathbf{C}) \mathbf{P}_k^-$$

Actualización
en el tiempo
(predicción)

Actualización
de medición
(corrección)

a priori


$$\hat{\mathbf{x}}_k^- = \mathbf{A} \hat{\mathbf{x}}_{k-1} + \mathbf{B} u_{k-1}$$

$$\mathbf{P}_k^- = \mathbf{A} \mathbf{P}_{k-1} \mathbf{A}^T + \mathbf{Q}$$

← $\hat{\mathbf{x}}_{k-1}, \mathbf{P}_{k-1}$
iniciales

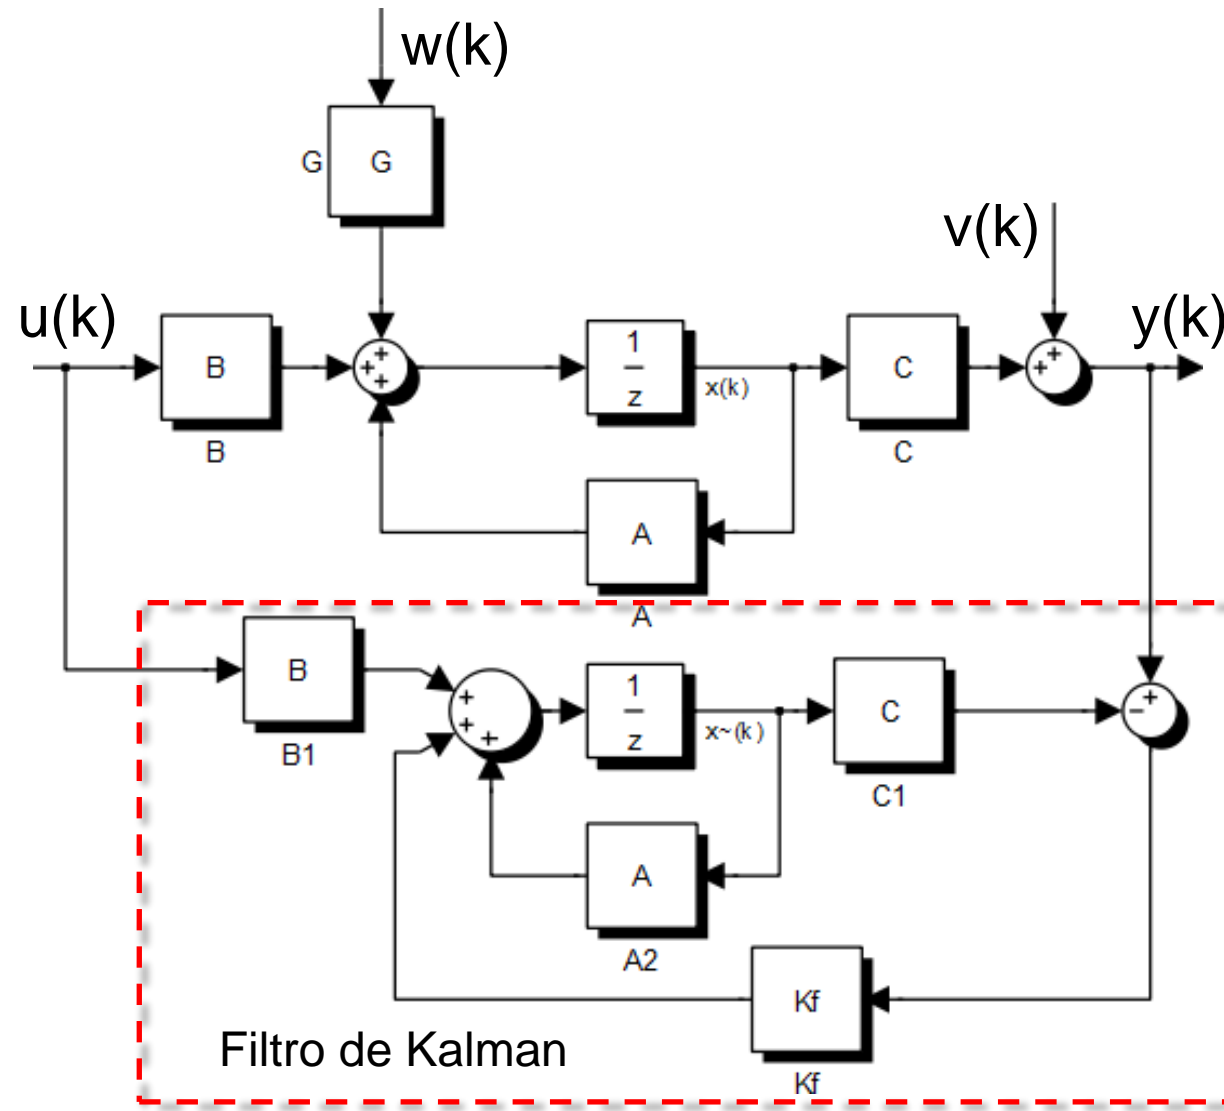

El filtro estima el proceso en un instante determinado y luego obtiene realimentación en la forma de una medición *ruidosa*.

Condiciones del filtro

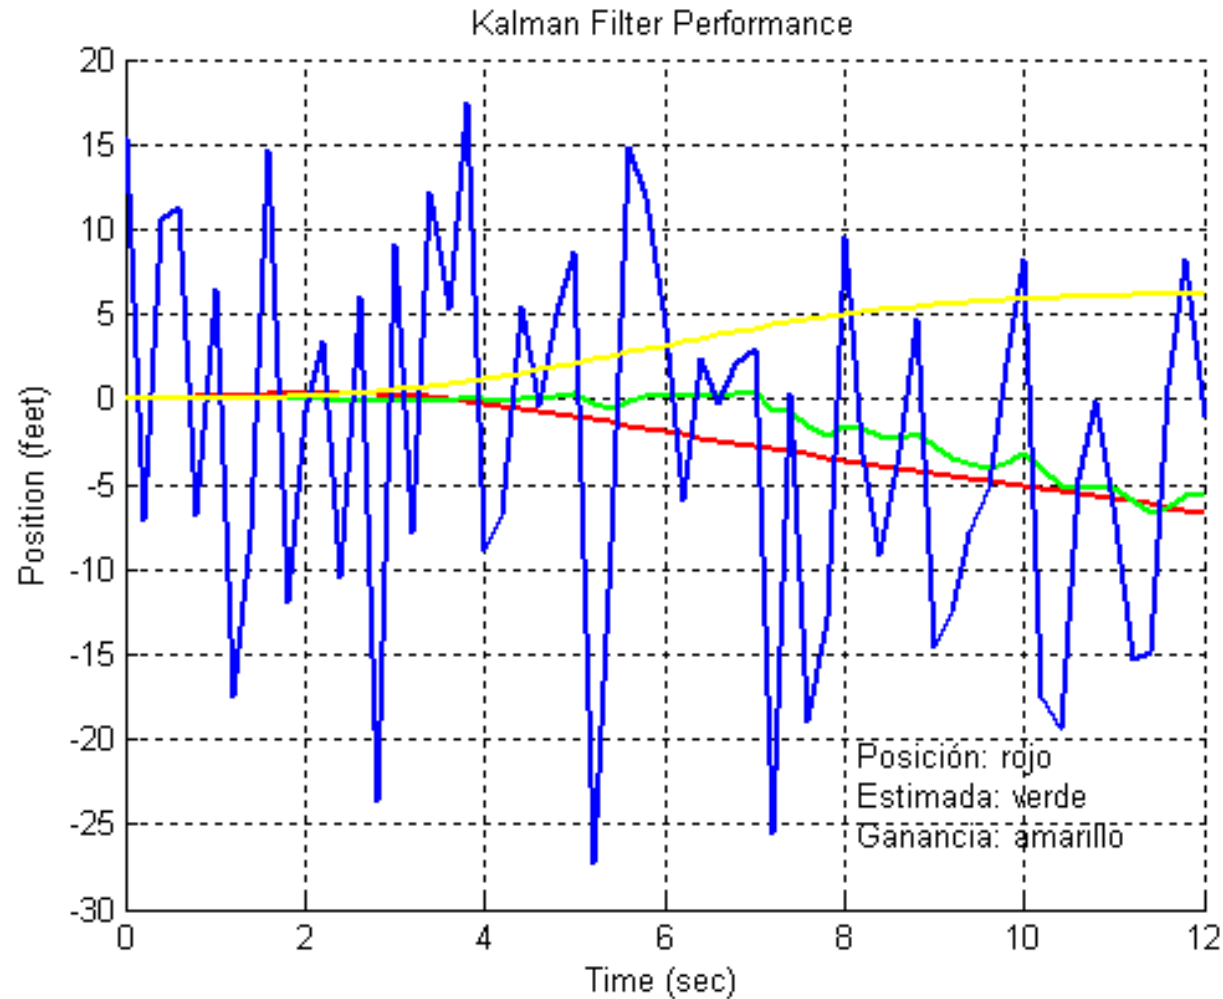



- Bajo las condiciones de que \mathbf{R} (varianza del ruido de medición) y \mathbf{Q} (varianza del ruido del proceso) son constantes; entonces, la covarianza estimada del error \mathbf{P}_k y la ganancia de Kalman \mathbf{K}_k , se estabilizarán rápido y permanecerán constantes.
- En este caso, ambas pueden ser calculadas fuera de línea, o encontrando el valor estático de \mathbf{P}_k .


Estimador con filtro de Kalman



Ejemplo 1: Filtro de Kalman



Ejemplo 2: Estimador de Kalman



- Usamos las funciones *reg*, *place* (MIMO) y *kalman* de Matlab para construir un estimador para la planta siguiente llamada sys, con $Q = 0.1$ y $R = 0.2$; donde los polos de la planta se deben ubicar en $s = -2 \pm i$.


$$\dot{\mathbf{x}} = \begin{bmatrix} 0 & 1 \\ -6 & -1 \end{bmatrix} \mathbf{x} + \begin{bmatrix} 0 & 1 \\ 1 & 0 \end{bmatrix} \begin{bmatrix} u \\ w \end{bmatrix}$$
$$y = \begin{bmatrix} 1 & 0 \end{bmatrix} \mathbf{x}$$

- $K = \text{place}(\text{sys.A}, \text{sys.B}, [-2+i \ -2-i])$
- $[K_{est}, K_f, P] = \text{kalman}(\text{sys}, Q, R)$
- $\text{Regulador} = \text{zpk}(\text{reg}(\text{sys}, K, K_f))$

$$\mathbf{K} = \begin{bmatrix} -7 & 1 \\ 2 & 2 \end{bmatrix}$$

$$\mathbf{K}_f = \begin{bmatrix} 0.2582 \\ -0.2167 \end{bmatrix}$$

Ejemplo 2: Resultados



■ Regulador y valores propios

$$\mathbf{K} = \begin{bmatrix} -7 & 1 \\ 2 & 2 \end{bmatrix}$$

$$\mathbf{K}_f = \begin{bmatrix} 0.2582 \\ -0.2167 \end{bmatrix}$$

$$K_1(s) = \frac{2.024(s + 2.622)}{(s^2 + 4.258s + 5.733)}$$

$$K_2(s) = \frac{-0.083046(s + 13.44)}{(s^2 + 4.258s + 5.733)}$$

Valores propios


$$-0.6291 + 2.3761i$$

$$-0.6291 - 2.3761i$$

$$-2.0000 + 1.0000i$$

$$-2.0000 - 1.0000i$$



Demo filtro de Kalman




```
clear all
% Definimos algunos parámetros
t=0:0.01:5;
omega=1;
x0=[-0.1 0.1];
%
% Generamos la señal u y el ruido n
u=sin(omega*t+1.2);
n=randn(size(t));
w=randn(size(t));
%
% Establecemos o medimos las covarianzas
Q=cov(0.2*w);
R=cov(0.2*n);
%
% Creamos el sistema
sys=ss([0 1;-6 -1],[0 1;1 0],[1 0],0)
```

```
% Calculamos el filtro de Kalman
[Kest,Kf,P]=kalman(sys,Q,R)
%
% Simulamos el sistema para obtener la salida y
y=lsim(sys,[u' 0.2*w'],t,x0);
%
% Creamos la salida ruidosa yn
yn=y+0.2*n;
%
% Estimamos la salida ye y el estado xe con u, yn
YY=lsim(Kest,[u',yn'],t);
%
% Graficamos los resultados
plot(t,u,t,y,t,yn,t,YY(:,1),'.')
legend('Entrada','Salida','Salida+ruido','Salida est.')
grid
```

Resultados de la simulación




Conclusiones (1)




- El algoritmo de Kalman se basa en un mecanismo de predicción y corrección, que permite minimizar el error.
- El algoritmo de Kalman recurre a realimentación de estado para la corrección del error.
- Se necesitan condiciones iniciales como el ruido del proceso y el ruido del sistema.
- Requiere que la media del ruido sea cero, es decir, ruido blanco y que la covarianza del ruido sea distinta de cero.

Ejercicios



- Tome los datos del precio diario en ventanilla del dólar (escoja un banco) US desde el 1 de enero 2019 hasta el día de ayer y haga la predicción del valor del USD para el día de hoy.
- Alternativamente puede hacer lo mismo con la tasa básica pasiva actualizada semanalmente cada jueves y predecir la de la próxima semana.
- Investigue sobre fusión de sensores por el método de Kalman.

Bibliografía



- [1] “An Introduction to the Kalman Filter”. Greg Welch and Gary Bishop
- [2] <http://www.innovatia.com/software>